Olist 平台增长质量与体验诊断报告

基于 Olist 巴西电商公开数据（2017-01 至 2018-08，96,203 笔有效订单）

作者：Michael · Oct 16, 2026 · 代码与数据处理：github.com/LeeMichael-L/olist-analytics

执行摘要

问题： Olist 的增长质量如何，哪些改进的投入产出最高？

结论一：增长完全依赖拉新，复购低是结构性的。 2018 年 1–8 月交易额是上年同期的 2.41 倍，几乎全部来自买家数增长（2.42 倍）；只有 2.15% 的买家会复购。即使首单准时送达，复购率也只有约 3%，改善履约最多多带来约 34 个复购买家。

结论二：体验的价值在口碑，约四成差评来自两个可识别的原因。 延误订单差评率 62.4%，准时订单 9.2%；延误约造成 28% 的差评，多件订单约 13%。近一半的延误集中在 3 个高峰月；72% 的延误发生在卖家准时发货之后，但卖家超时会让延误风险升至 3.9 倍。

结论三：供给侧的问题集中、可管理。 前 20% 的卖家贡献 82% 的 GMV；40 个头部问题卖家每家多造成 20 多条差评。新卖家签约后，57% 在 90 天内一单未卖。

杠杆对比（分析期内可减少的差评数，静态上限，各项不可相加）：

杠杆	可减少差评	难度
多件订单差评率降到单件水平	约 1,535（12.6%）	未知，需先诊断
高峰月延误率降到平常水平	约 1,155（9.4%）	中
消除卖家发货超时	约 880（7.2%）	低
40 个头部问题卖家整改到平均水平	约 860（7.0%）	低
RJ 平常月延误率降到 SP 水平	约 150（1.2%）	高

优先建议：

1. **短期**：对全部卖家推行发货提醒与超时规则，并按损害整改 40 个头部问题卖家。
2. **中期**：为黑色星期五、年初等高峰期准备物流运力预案。
3. **先诊断**：查明多件订单差评高的原因，它是单项最大的杠杆，但原因未知。

局限： 结论基于历史观察数据，表示关联而非严格因果；杠杆为静态上限估算，建议先小范围验证再推广。

1 背景与方法

本报告回答一个问题：Olist 的增长质量如何，哪些改进的投入产出最高？

Olist 是连接巴西中小卖家与各大电商平台的服务商，收入来自卖家的订阅费和佣金。卖家是 Olist 的直接客户；买家的评分影响卖家表现，进而影响平台口碑。

数据。 Olist 公开的两个数据集：订单数据（约 10 万笔订单，2016-2018）和营销漏斗数据（8,000 条卖家线索、842 个签约卖家）。分析窗口为 2017-01 至 2018-08，有效订单为已送达、且状态与时间戳一致的订单，共 96,203 笔。

北极星指标。 已送达订单的商品交易额（GMV，不含运费），合计约 1,318 万雷亚尔（BRL）。它反映平台交易规模，但不等于 Olist 的收入。

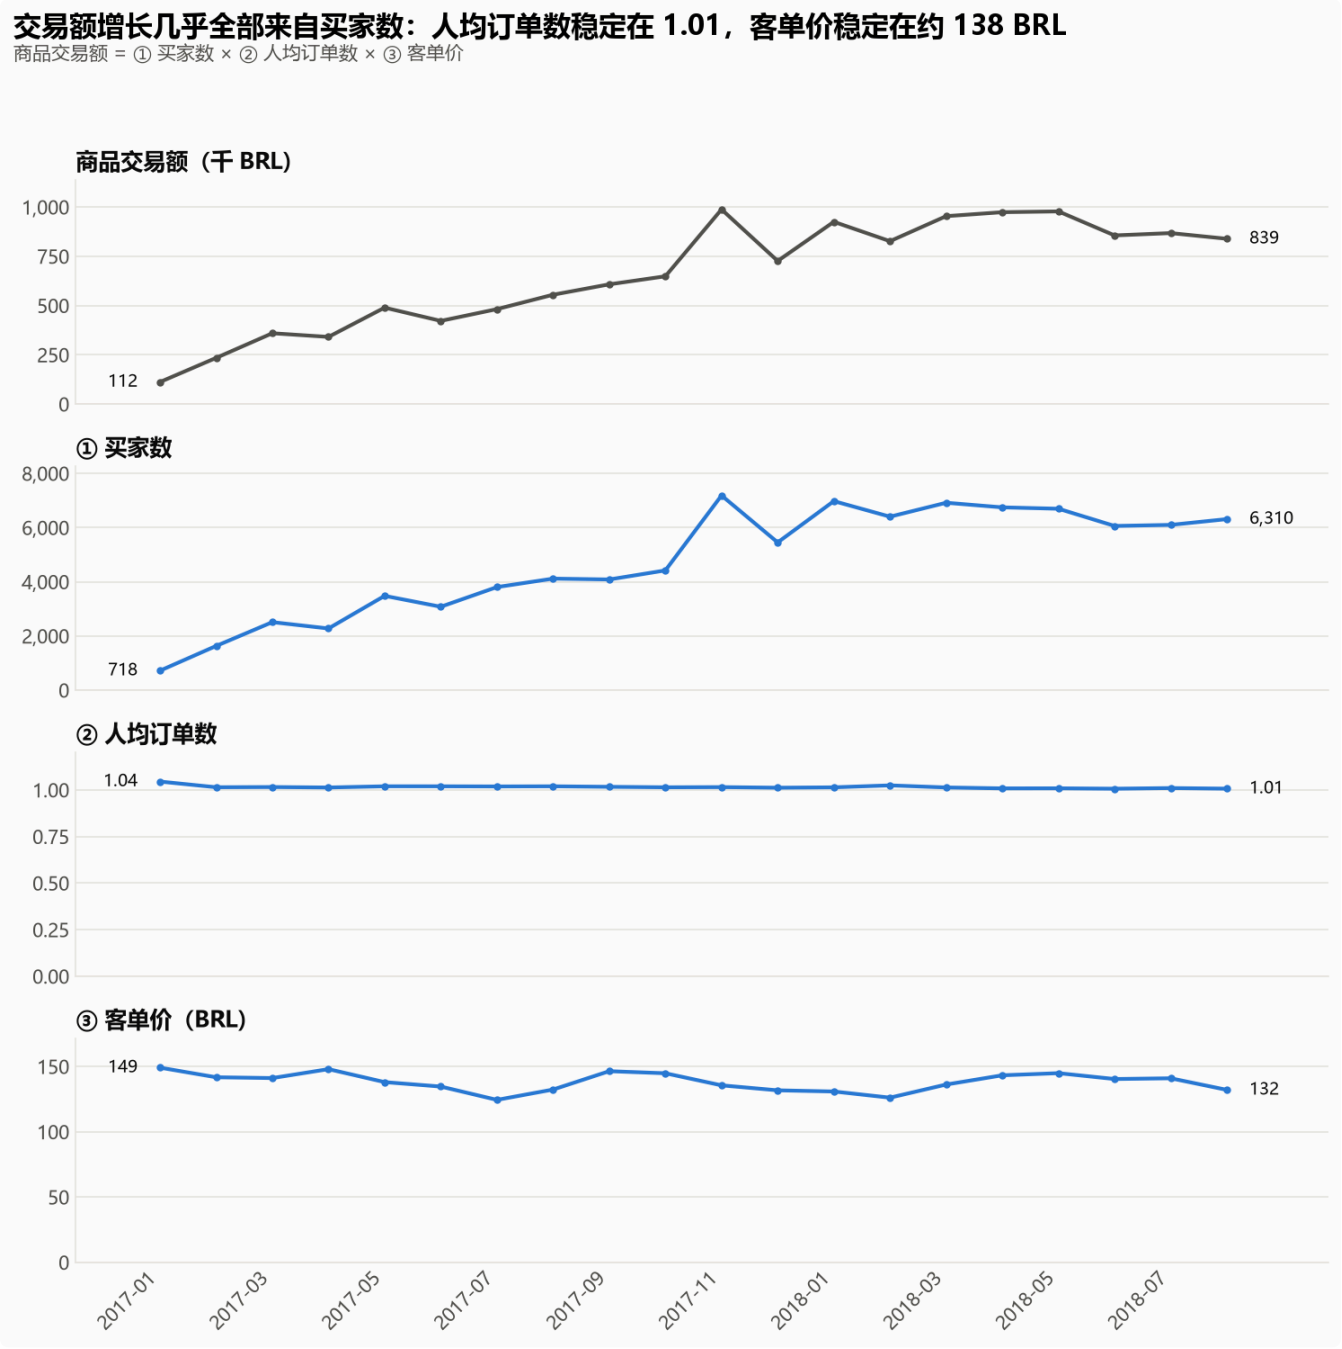
方法。 原始数据经过四层建模（原始层、明细层、主题宽表、结果表），约 40 项数据质量检查，34 条口径决策均有记录。主要结论都做了敏感性分析：替换口径、调整阈值、按时期拆分，并在正文中如实报告对结论幅度影响较大的口径。口径定义与检验结果见附录。

本报告的分析均基于历史观察数据，能说明关联与可能的原因，但不等于实验证明的因果效果。

2 增长完全依赖拉新，复购低是结构性的

2.1 交易额的增长几乎全部来自买家数

交易额 = 买家数 × 人均订单数 × 客单价。三个因子中，只有买家数在增长。 2018 年 1–8 月与 2017 年同期相比，买家数为 2.42 倍，交易额为 2.41 倍；人均订单数始终在 1.01 左右，客单价在 124–149 BRL 之间波动。



月度买家数从 2017 年 1 月的 718 人增长到 2018 年每月 6,000–7,000 人，自 2018 年起不再增长，交易额也随之进入平稳期。增长要继续，只有两条路：继续拉新，或让买家回来复购。

2.2 只有约 2% 的买家会回来复购

93,096 个买家中，只有 2.15% 在两个及以上不同日期下过单；复购订单只贡献 2.15% 的交易额。 同一天的多笔订单多为一次购物被拆单，不计为复购；若按“下过 2 单及以上”计算为 3.00%。



> 这是复购率的下限：2018 年首购的买家观察时间更短，复购率只有 1.37%，2017 年首购的为 3.10%。

2.3 首单体验对复购的影响很小

复购率低不是体验造成的：即使首单体验完美，复购率也只有约 3%。 只看 2018 年 3 月前首购的 55,265 个买家（保证至少约半年观察期）：

首单体验	买家数	后续复购率
准时送达	51,594	2.9%
延误送达	3,671	2.0%
打 5 分	31,836	3.1%
打 1 分	5,449	2.3%

首单延误确实让复购率下降约 0.9 个百分点（$p \approx 0.001$），但影响很小：就算首单延误的 3,671 个买家全部准时送达，也只会多出约 34 个复购买家。

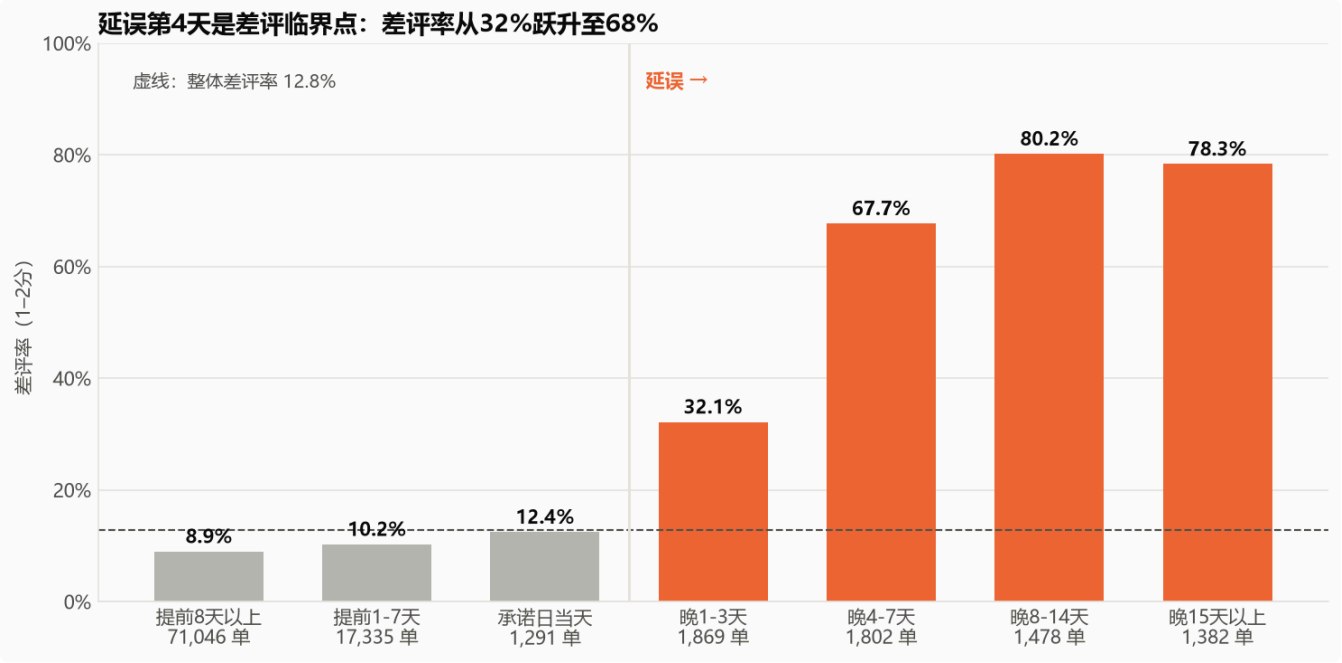
含义： 复购低是结构性的。一个可能的原因是买家在大电商平台上下单，未必知道背后是 Olist（数据无法验证）。所以改善履约无法明显提升复购。那么体验的价值在哪里？答案是口碑：差评会影响卖家评分和新买家的信任。下一章拆解差评从哪里来。

3 差评从哪来：延误和多件订单是两个最大的可识别来源

本章拆解分析期内全部 12,228 条差评的来源：哪些原因可以识别、各占多少、又集中在哪里。

3.1 延误让差评率成倍上升，延误第 4 天是临界点

延误订单的差评率为 62.4%，准时订单只有 9.2%（6.8 倍）；延误超过 3 天后，差评率从约 32% 跳到 68%。

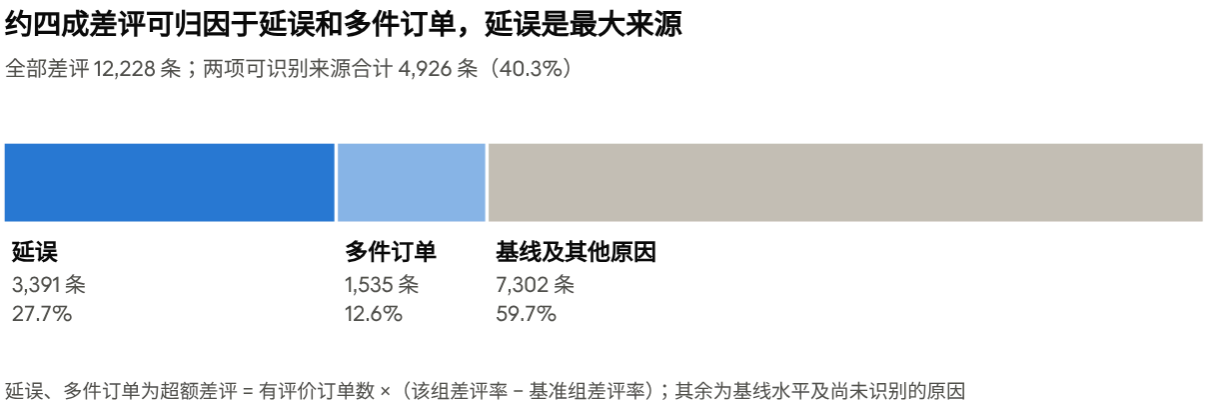


提前或当天送达的订单差评率在 9%–12% 之间；延误 1–3 天升至 32.1%，4–7 天升至 67.7%，此后稳定在 80% 左右。买家对短暂延误尚能容忍，超过 3 天后体验急剧恶化，所以对延误 3 天仍未送达的订单主动干预，是成本最低的补救窗口。

> 口径提示：延误订单的评价中有 74%（4,749 / 6,378）写于收货之前，多为“还没收到货”的投诉。只看收货后的评价，延误订单差评率为 25.1%，是准时订单的 2.7 倍。两种口径下延误都是最大的差评来源，引用效应大小时应给出 2.7–6.8 倍的范围。

3.2 延误约造成 28% 的超额差评，多件订单约 13%

延误订单贡献了 32.6% 的差评，但其中一部分即使准时送达也会发生。扣除这部分基线后，延误约造成 28% 的差评，多件订单约 13%，两者合计约四成。



python/s2_impact_sizing.ipynb · 2017-01 至 2018-08 全部有评价订单

多件订单是延误之外最大的来源：只看准时送达的订单，单件订单差评率 7.5%，多件且同一卖家 21.0%，多件且多个卖家 46.9%（$p < 0.001$）。可能的原因有分开发货、缺件或部分送达，但现有数据无法确认，需要先诊断再行动。

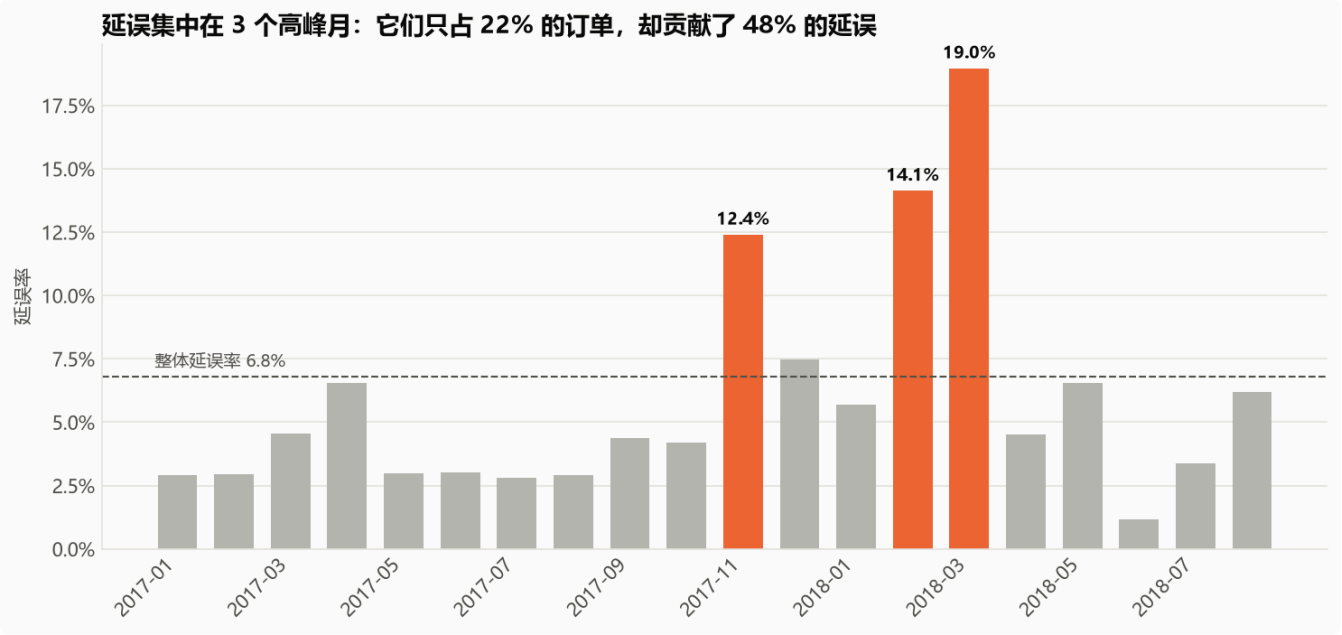
其余约六成差评属于基线水平（即使准时送达的单件订单，也有约 7.5% 的差评率）和尚未识别的原因（如商品质量、描述不符），需要评论文本才能继续拆解。

> 超额差评是对比估算，不是因果证明：延误订单、多件订单与对照组之间可能还有其他差异（如品类、价格）。

延误是差评的最大来源。但延误是常态，还是集中在某些时期和地区？

3.3 近一半的延误集中在 3 个高峰月

2017-11、2018-02、2018-03 三个月只占 21.7% 的订单，却贡献了 48.4% 的延误订单。



高峰月的延误率为 12%–19%，其余月份多在 2%–5%。2017 年 11 月与黑色星期五大促重合；2018 年 2–3 月延误偏高的原因，现有数据无法确认。按时期拆分后，几个看起来是“常态”的问题，其实主要由高峰月放大：

- **跨州订单**：平常月的延误率是同州订单的 1.31 倍，高峰月为 2.56 倍。合并计算的 1.8 倍（8.2% vs 4.6%）主要来自高峰月。
- **RJ 州**：平常月延误率 6.6%（SP 3.6%、MG 2.4%），高峰月达 31.2%。RJ 占全国延误订单的 22.9%，只看平常月则为 18.8%。RJ 的问题常态存在，但被高峰月明显放大。
- **延误与差评的关系在两个时期都成立**：平常月延误订单差评率 56.9%（准时 9.0%），高峰月 68.3%（准时 10.3%）。

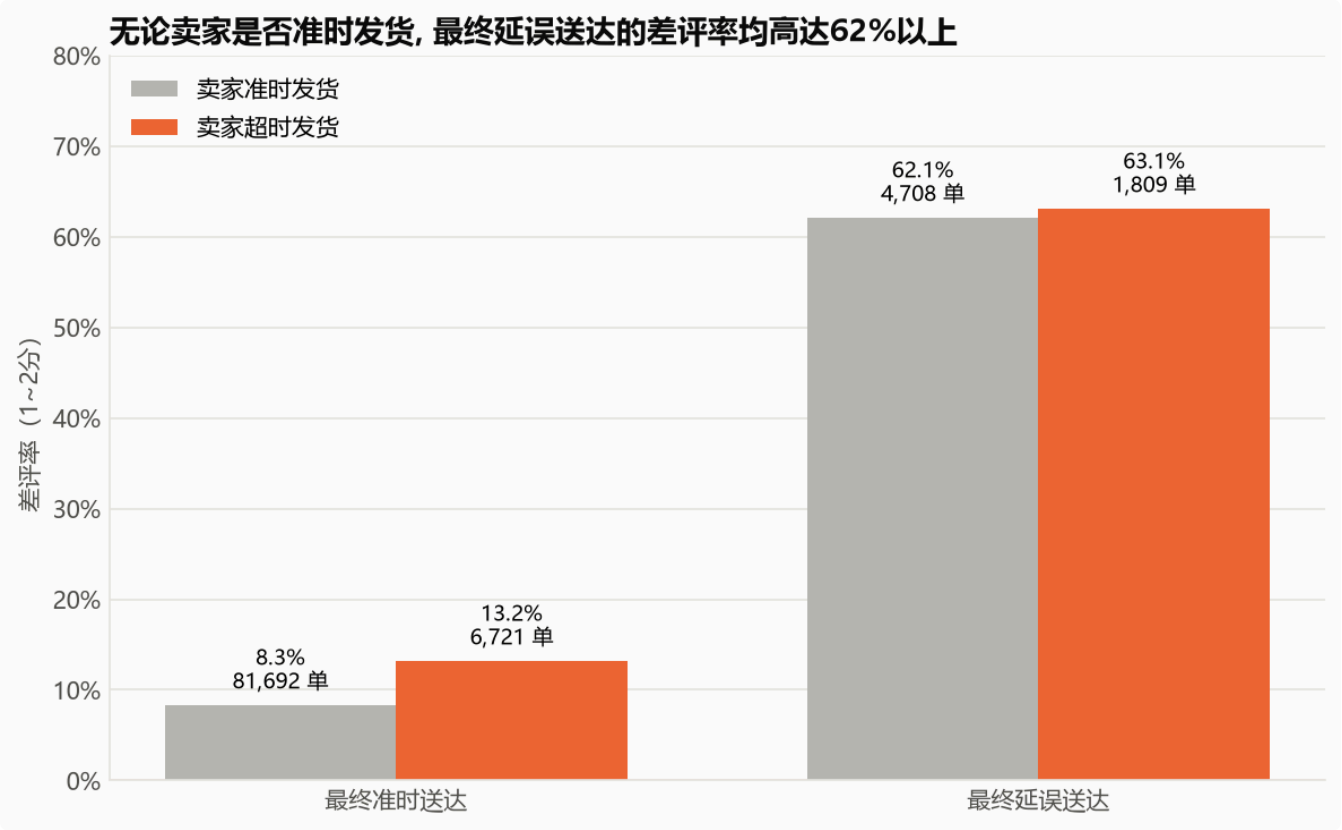
含义： 延误主要是高峰期的运力问题，而不是某个地区的常态问题。为高峰期准备运力预案，收益远大于区域性的常态治理。

> 延误率依赖承诺日期：北部偏远州（AM、AP、RO、AC）的承诺期长达 39–47 天，延误率不到 4%，但差评率并不低。延误率低不等于配送体验好。

延误主要发生在物流环节，还是卖家发货环节？

3.4 延误主要来自物流，但卖家发货超时本身也会带来差评

72% 的延误订单中，卖家是准时发货的，延误主要来自物流环节。但卖家发货超时会让延误风险从 5.4% 升到 21.2%（3.9 倍）。



图中有两个发现：

- **订单一旦延误，买家不在乎是谁的责任**：无论卖家是否超时发货，延误订单的差评率都在 62%–63%（p = 0.47）。
- **即使最终准时送达，卖家超时仍会带来差评**：差评率 13.2% vs 8.3%。为排除“超时的卖家本身质量就差”这一干扰，我在 1,074 个同时有两类订单的卖家内部做对比：发货超时本身让差评率高约 2.8 个百分点（95% 置信区间 1.8–3.7），其余差距来自超时卖家整体质量较差。

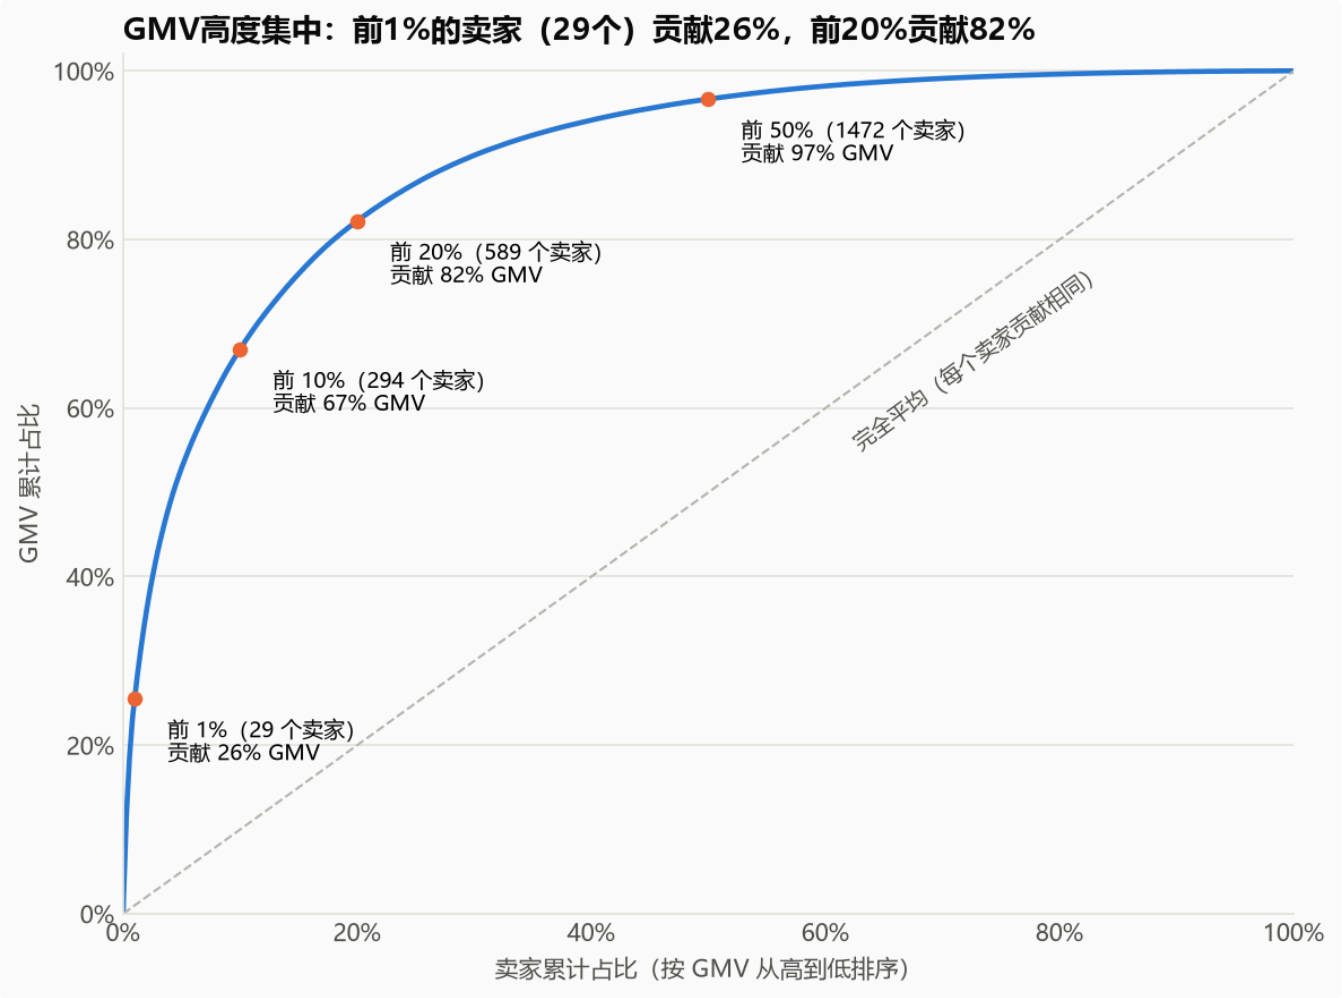
含义： 卖家发货超时只涉及约 9% 的订单，但它是平台可以直接用规则约束的延误源，每一单的延误风险和差评风险都明显更高。

延误和差评在卖家之间是平均分布的吗？下一章转向供给侧。

4 供给侧：GMV 和问题都集中在少数卖家，新卖家大多没有起步

4.1 前 20% 的卖家贡献 82% 的 GMV，80% 的卖家数据太少、无法单独评估

2,945 个有成交的卖家中，前 1%（29 个）贡献 26% 的 GMV，前 20% 贡献 82%，后 50% 只贡献约 3%。

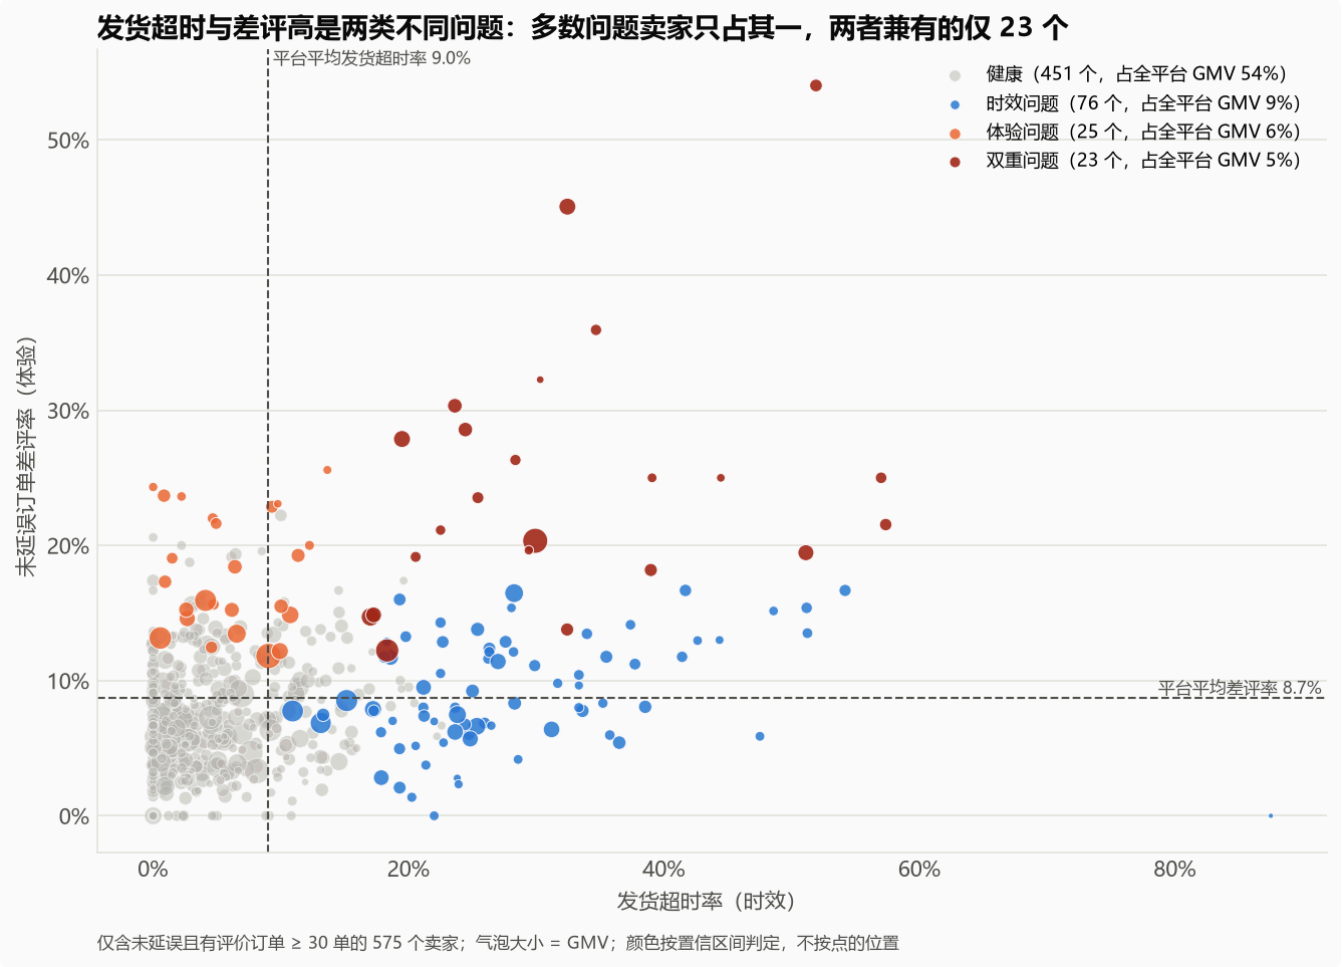


卖家 GMV 中位数约 850 BRL（20 个月合计），一半卖家平均每月不到一单。2,370 个卖家（80%）的未延误有评价订单不足 30 单，无法单独判断好坏，合计贡献 25% 的 GMV。

含义： 头部卖家可以逐个管理；长尾卖家只能用平台级规则（自动发货提醒、超时预警）统一管理。

4.2 40 个头部问题卖家是差评治理的重点

用两个卖家可控的指标（未延误订单差评率、发货超时率）对 427 个样本充足的头部卖家分类：328 个健康，59 个时效问题，21 个体验问题，19 个双重问题。 只有指标的 95% 置信区间下限高于平台平均时，才判定为有问题，避免把小样本的偶然波动当成问题。



三类问题卖家合计占全平台 GMV 的 20%，且两类问题大多不重叠。按比平台平均多造成的差评计算，每个双重问题卖家约 26 条，体验问题约 21 条，时效问题只有约 2 条。因此体验问题和双重问题这 40 个卖家是治理重点；它们集中在家居类（床品、办公家具、家居装饰），可能与体积大、易损坏有关。

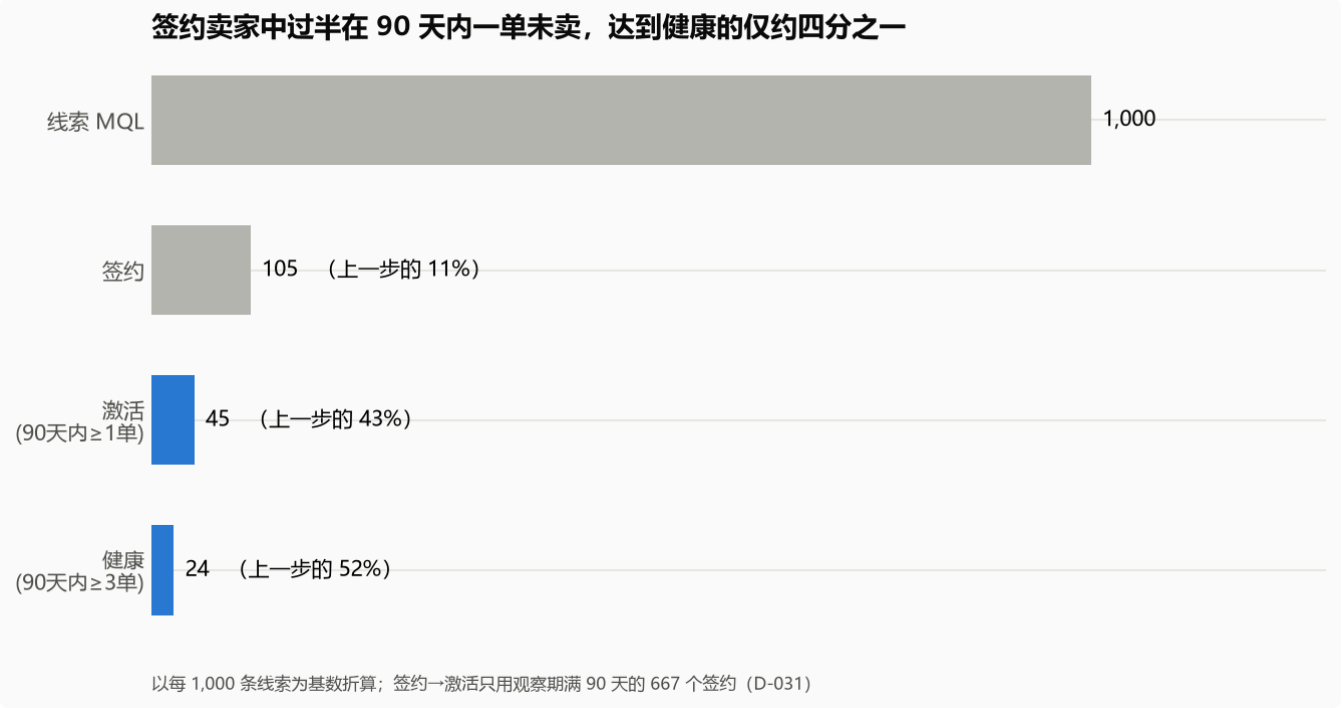
含义： 不需要全面整顿卖家，按损害整改 40 个卖家即可。时效问题卖家数量多但单个损害小，适合用平台规则统一约束。

> 稳健性：将样本门槛、头部范围、置信水平分别调整（7 种情景），头部问题卖家的 GMV 占比始终在 17%–22%，损害排序不变；只用单件订单重新分层时，40 个卖家中有 34 个（85%）仍被判为有体验问题。

存量卖家的问题集中在少数头部，那么新卖家呢？平台签入的新卖家，有多少真正开始经营？

4.3 签约后 57% 的卖家 90 天内一单未卖

每 1,000 条营销线索最终带来 105 个签约、45 个激活、24 个健康卖家。线索到签约的流失比例最大，但签约后的流失更值得关注。



观察期满 90 天的 667 个签约卖家中，57% 在 90 天内一单未卖，21% 只卖了 1–2 单，只有 22% 达到健康（≥ 3 单）。激活既慢又匀速：签约到首单的中位时间为 39 天，签约 30 天时只有 16.5% 的卖家卖出首单。这与 4.1 的长尾相互印证：很多卖家从签约起就没有真正起步。

按获客渠道拆分，差异出在签约之后：付费搜索与自然搜索的签约率相同（12.3% vs 11.8%，$p = 0.64$），但签约后 90 天激活率更高（55% vs 39%，$p = 0.003$）。社交媒体的问题在线索阶段，签约率只有 5.6%。另有 14.5% 的线索来源记录为 unknown，渠道追踪不完整。

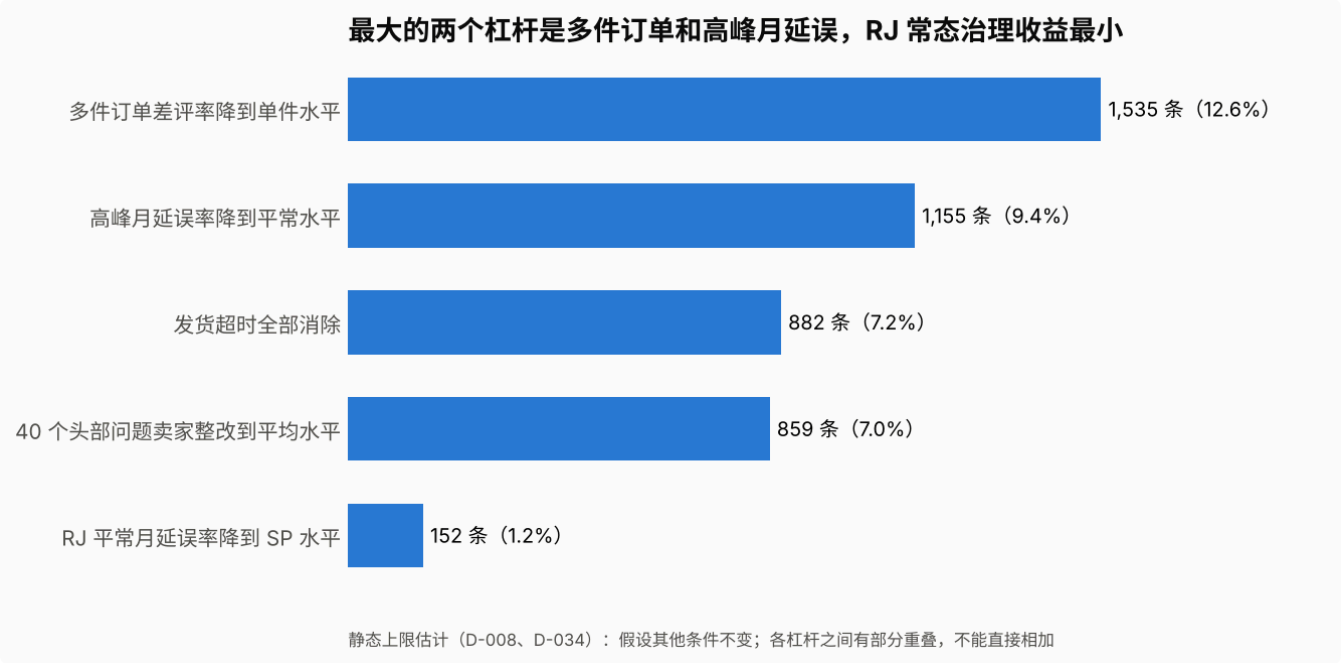
含义： 签约不等于有了供给。入驻扶持应前置到签约后约第 14 天（此时只有 7% 的卖家已开始卖货）；渠道预算怎么分配，还需要获客成本数据。

> 口径提示：只统计观察期满 90 天的签约。观察期不完整的签约“卖过货”的比例只有 19%，完整的为 51%，不加区分会严重低估激活率。观察窗口改为 60 / 120 天时，一单未卖的比例为 68% / 52%，结论不变。

前三章找到了问题在哪里。下一章把它们换算成同一个单位，比较哪些改进最值得先做。

5 建议与优先级：先做低难度的卖家规则，再做高峰运力，多件订单先诊断

把各项改进统一换算成“分析期内可减少的差评数”后，最大的两个杠杆是多件订单和高峰月延误，RJ 常态治理的收益最小。



> 测算口径：假设对应问题改善到基准水平（如多件订单差评率降到单件水平、高峰月延误率降到平常月水平），按分析期的订单量计算可减少的差评。这是静态上限，各杠杆之间有部分重叠（如高峰月的延误中也包含卖家超时），不能直接相加。

结合实施难度，建议按以下顺序推进：

优先级	行动	依据	难度	可减少差评（上限）
短期	对全部卖家推行发货截止前自动提醒，持续超时再处罚	超时让延误风险升至 3.9 倍，超时本身也带来差评（3.4）	低	约 880（7.2%）
短期	按损害整改 40 个头部体验 / 双重问题卖家：双重问题限期整改并降低流量，体验问题先查差评原因	每家多造成 20 多条差评（4.2）	低	约 860（7.0%）
短期	对晚于承诺 3 天仍未送达的订单主动干预（如主动告知进度）	延误第 4 天是差评临界点（3.1）	低	未测算
中期	为高峰期（黑色星期五、年初）准备物流运力预案，高峰期适当放宽承诺日期	近一半的延误集中在 3 个高峰月（3.3）	中	约 1,155（9.4%）
先诊断	查明多件订单差评高的原因（分开发货、缺件、部分送达），再决定改进方式	单项最大的杠杆，但原因未知（3.2）	未知	约 1,535（12.6%）

优先级	行动	依据	难度	可减少差评（上限）
供给	入驻扶持前置到签约后第 14 天；补全渠道追踪与获客成本数据	57% 的签约卖家 90 天内未开单（4.3）	低	不以差评计
降低优先级	RJ 州的常态物流治理	平常月差距小，问题主要由高峰月放大（3.3）	高	约 150（1.2%）

复购没有出现在清单上：第 2 章表明，即使首单全部准时，也只会多出约 34 个复购买家。因此上述体验改进的目标是减少差评、保护口碑；增长本身仍要靠拉新和健康的卖家供给。

每项行动上线后，可以用差评率和按时送达率追踪效果；上述数字是估算，建议先在部分卖家或品类上小范围验证，再全面推广。下一章说明这些结论的局限。

6 局限与下一步

6.1 局限

- **观察数据，不是实验。** 超额差评、卖家内部对比都只能控制部分干扰因素（如品类、价格、季节），结论表示“相关且方向一致”，而不是严格的因果效应。
- **杠杆为静态上限。** 不考虑实施成本和买家行为的变化，各杠杆互有重叠，不能相加。
- **评价的口径影响效应大小。** 延误订单的评价大多写于收货前，延误的效应在 2.7–6.8 倍之间；没有评价的订单延误率（23.8%）是有评价订单（6.7%）的 3.5 倍，只用有评价订单计算差评可能低估延误的影响。
- **复购率是下限。** 分析期末首购的买家观察时间不足；买家可能并不知道自己是在 Olist 的卖家处购物，这一点无法用数据验证。
- **数据缺口。** 未分析评论文本（约六成差评原因未识别）；没有承运商信息（无法解释 RJ 和高峰月的延误原因）；没有渠道成本（无法评估获客投入产出）；没有佣金数据，GMV 不等于 Olist 收入。
- **覆盖范围。** 多卖家订单（1.3%）未纳入卖家体验指标；漏斗中观察期完整的签约只有 667 个，按渠道拆分后部分组样本较小。

6.2 下一步

1. **评论文本分析**：拆解剩余约六成差评的原因（商品质量、描述不符、运输破损等）。
2. **多件订单诊断**：按是否分开发货、各件交付时间差等维度拆分，确认最大杠杆的原因。
3. **品类分析**：验证家居类问题卖家是否与商品体积、易损有关。
4. **同期群留存与在售卖家流失**：在处理右删失的前提下，追踪买家和卖家的长期表现。
5. **小范围实验**：用 A/B 测试验证发货提醒和延误第 3 天主动干预的实际效果。

附录

A 术语与口径

术语	口径
有效订单	状态为已送达、状态与时间戳无矛盾的订单，分析窗口内共 96,203 单
GMV（商品交易额）	有效订单的商品金额之和，不含运费，不等于 Olist 收入
差评	评分为 1–2 分；一单多条评价时取最后作答的一条
延误	实际送达日期晚于承诺送达日期
卖家发货超时	单卖家订单中，交给物流的时间晚于发货截止时间
复购	在 2 个及以上不同日期下过有效订单
超额差评	有评价订单数 ×（该组差评率 − 基准组差评率）
高峰月	月度延误率超过 10% 的月份：2017-11、2018-02、2018-03
头部卖家	GMV 排名前 20% 的卖家
样本不足	未延误且有评价的单卖家订单少于 30 单
置信区间下限	在 95% 的把握下，卖家真实比率至少有这么高；下限仍高于平台平均，才判定为有问题
激活 / 健康 / 流失	签约后 90 天内有效订单 ≥ 1 单 / ≥ 3 单 / 0 单
右删失	观察期未结束，结果还没来得及发生；不处理会低估复购率和激活率

B 稳健性检验汇总

检验	结果	结论是否改变
改用首次评分、排除时间戳异常、多卖家订单按主卖家归属	差评率变动均不超过 0.5 个百分点	否
排除收货前写的评价	延误的差评倍数从 6.8 降至 2.7	方向不变，幅度变小
按平常月 / 高峰月拆分	跨州 1.31 倍 vs 2.56 倍；RJ 延误率 6.6% vs 31.2%	跨州与 RJ 的效应主要在高峰月

检验	结果	结论是否改变
卖家分层阈值（7 种情景）	头部问题卖家 GMV 占比 17%–22%，损害排序不变	否
只用单件订单重新分层	40 个中 34 个仍有体验问题	否
卖家内部对比的评价门槛（1 / 3 / 5 条）	超时带来的差评率增幅 2.8–2.9 个百分点	否
漏斗观察窗口（60 / 90 / 120 天）	90 天内未开单比例 68% / 57% / 52%	否

C 关键口径决策

完整的决策记录（D-001 至 D-034）见仓库 `docs/decision_log.md`。与本报告结论直接相关的有：

编号	决策	对应章节
D-004	GMV 只算商品金额，不含运费	第 2 章
D-008	情景测算标注为静态上限	第 5 章
D-013	多条评价取最后一条	第 3 章
D-016	分析窗口 2017-01 至 2018-08	全文
D-021	收货前的评价保留并做敏感性分析	3.1
D-022	复购按不同日期计算	2.2
D-024	无评价订单保留在宽表中	6.1
D-029	卖家体验指标只用单卖家订单	4.2
D-030	卖家分层规则	4.2
D-031	漏斗激活与健康的 90 天观察窗口	4.3
D-032	高峰月定义	3.3
D-033	首单体验只用 2018-03 前首购的买家	2.3
D-034	建议统一换算为可减少的差评数	第 5 章

D 复现

代码与文档见 github.com/LeeMichael-L/olist-analytics。环境为 MySQL 8.0 及以上、Python 3.13。

1. 从 Kaggle 下载 Olist 主数据集和营销漏斗数据集，放入 `data/raw/`。
2. 按 `sql/01_ods` → `02_dwd` → `03_dws` → `04_ads` 的顺序执行建表脚本，每个脚本末尾都有核对查询。
3. 在 `python/` 中按 `s1_overview` → `m1` → `m5` → `m3` → `m6` → `m7` → `s2_impact_sizing` 的顺序运行 notebook，本报告的全部图表和数字均由此生成。