Olist 平台增长质量与体验诊断报告

基于 Olist 巴西电商公开数据（2017-01 至 2018-08，96,203 笔有效订单）

作者：Michael · Oct 17, 2026 · 代码与数据处理：github.com/LeeMichael-L/olist-analytics

执行摘要

问题： Olist 在保持交易规模增长的同时，如何提升买家满意度和卖家质量？哪些改进的投入产出最高？

答案： 2018 年的增长受需求限制，增加卖家并不能增加 GMV。体验改进的价值在于保护 GMV：差评会压低卖家之后的销量。约四成差评来自两个可以改进的机制，即**承诺日期没有兑现**和**多件订单收货不完整**；投入产出最高的改进，正是针对这两个机制和少数问题卖家的改进。

三个行动

行动	预期影响（分析期内可减少的差评）	如何验证
1 卖家规则（短期，低难度）：发货截止前提醒，持续超时再处罚；按损害整改头部问题卖家	发货超时约 393~882 条；问题卖家约 782~859 条	先对部分卖家上线提醒，比较超时率与差评率；整改卖家与同类未整改卖家对比
2 多件订单完整交付（中期，系统改造）：按包裹追踪，全部送达才标记已送达，缺件主动补发	约 1,165~1,535 条，单项最大	选部分品类试点，比较多件订单差评率
3 承诺日期动态校准（中期，系统改造）：监控运输时长，变慢时自动放宽承诺	高延误月约 39% 的延误可变为按时，约 190~635 条	A/B 测试，同时监控下单转化率

各行动的差评数有重叠，不能相加。按每条差评约对应下个月 68 BRL 的 GMV 换算，单项约为分析期 GMV 的 0.3%~0.8%。

主要局限： 结论基于历史观察数据，表示关联而非严格的因果；杠杆为静态估计，放宽承诺对下单转化的影响需要实验验证。

1 背景与方法

本报告回答一个问题：Olist 在保持交易规模增长的同时，如何提升买家满意度和卖家质量？哪些改进的投入产出最高？

Olist 是连接巴西中小卖家与各大电商平台的服务商，收入来自卖家的订阅费和佣金。卖家是 Olist 的直接客户；买家的评分影响卖家在各平台上的表现，进而影响平台。

数据。 Olist 公开的两个数据集：订单数据（约 10 万笔订单，2016-2018）和营销漏斗数据（8,000 条卖家线索、842 个签约卖家）。分析窗口为 2017-01 至 2018-08，有效订单为已送达、且状态与时间戳一致的订单，共 96,203 笔。

北极星指标。 已送达订单的商品交易额（GMV，不含运费），合计约 1,318 万雷亚尔（BRL）。它反映平台交易规模，但不等于 Olist 的收入。买家满意度用差评率（1~2 分的评价占比）衡量。

方法。 原始数据经过四层建模（原始层、明细层、主题宽表、结果表），约 40 项数据质量检查，39 条口径决策均有记录。主要结论都做了敏感性分析。写报告时，我又对每个准备写进报告的说法做了回头检验，推翻了两处早期解释（3.2、3.3 节），检验过程保留在仓库的 `s2_report_checks.ipynb` 中。

本报告的分析均基于历史观察数据，能说明关联与可能的机制，但不等于实验证明的因果效果。

2 增长：受需求限制，体验是 GMV 的护栏

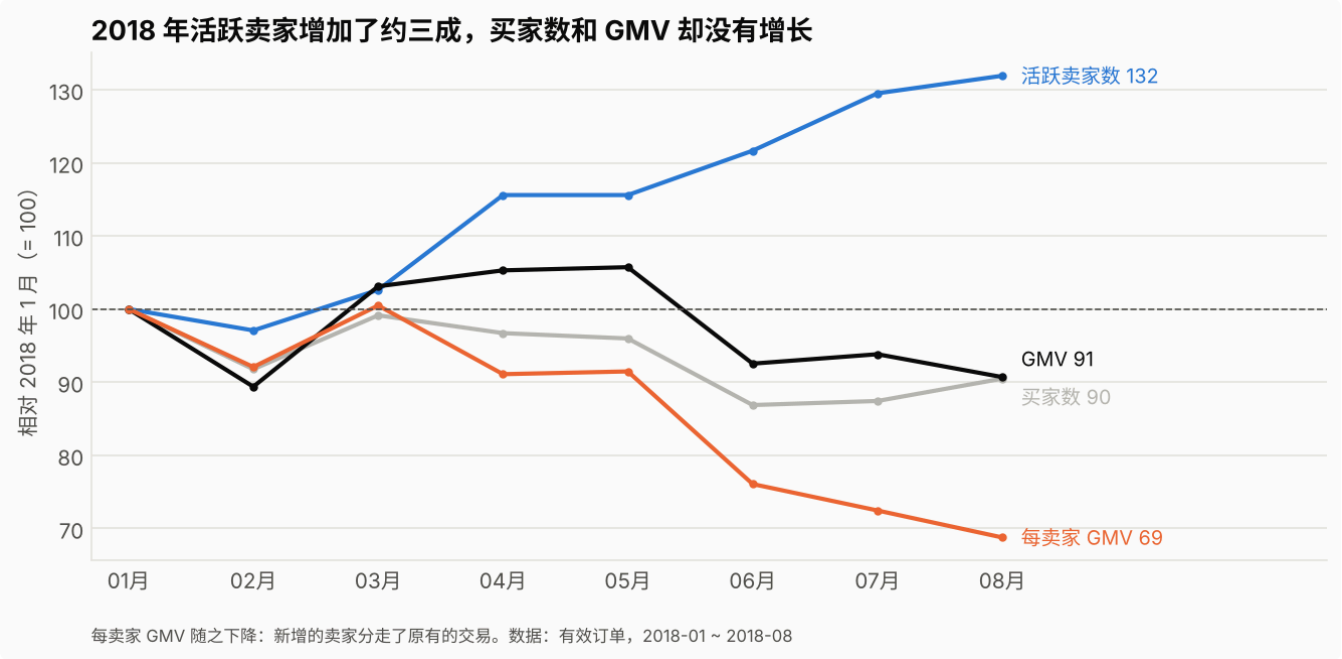
2.1 GMV 的增长来自买家数，而买家数在 2018 年不再增长

GMV = 买家数 × 人均订单数 × 客单价。2018 年 1~8 月 GMV 是上年同期的 2.41 倍，几乎全部来自买家数（2.42 倍）。 人均订单数始终在 1.01 左右，客单价在 124~149 BRL 之间波动。月度买家数从 2017 年 1 月的 718 人增长到 2018 年初的约 7,000 人后不再增长，GMV 随之进入平稳期。

复购也帮不上忙：93,096 个买家中只有 2.15% 在两个及以上不同日期下过单，复购订单只贡献 2.15% 的 GMV。2018 年首购的买家观察时间较短，复购率只有 1.37%，所以 2.15% 是下限。

2.2 卖家在增加，GMV 没有：新增卖家在分存量

2018 年 8 月与 1 月相比，活跃卖家增加 32%，买家数和 GMV 却下降约 10%，每卖家 GMV 下降 31%。



2018 年新出现的卖家占当年活跃卖家的 54%，只贡献了 30% 的 GMV，平均每家约为老卖家的三分之一。供给在增加，需求没有跟上，增加卖家数量本身不会增加 GMV。

含义： 增长的瓶颈在需求端。卖家获取的目标应是质量（体验更好、补足品类），而不是数量（见 4.3 节）。

2.3 复购低是结构性的，首单体验能解释的部分很小

只看 2018 年 3 月前首购、有约半年以上观察期的 55,265 个买家：首单准时送达的复购率为 2.9%，延误的为 2.0%（相对低约 31%，p ≈ 0.001）。 首单打 5 分的买家复购率 3.1%，打 1 分的 2.3%。差异显著，但即使这批买家的首单全部准时，也只会多出约 34 个复购买家；无论首单体验如何，复购率都不超过约 3%。

> 这是观察数据下的估计，只能说明首单体验能解释的部分很小。复购低的原因可能是买家在大电商平台下单，未必知道背后是 Olist，现有数据无法验证。

2.4 但差评会压低卖家之后的销量

同一卖家某个月的差评率比它自己的平常水平高 10 个百分点，下个月 GMV 约低 4%~10%。 这个估计来自 883 个卖家、4,202 个"卖家 × 月份"的逐月对比，控制了卖家本身、月份和当月规模。不同卖家之间直接比较时噪音大、方向不稳定，因为卖家的品类和规模差异太大。

换算下来，每条差评约对应下个月 68 BRL 的 GMV 损失，约为半笔订单。

含义： 体验改进不会带来新的增长，但能保护卖家的销量。第 5 章用这个系数把各项改进换算成 GMV。

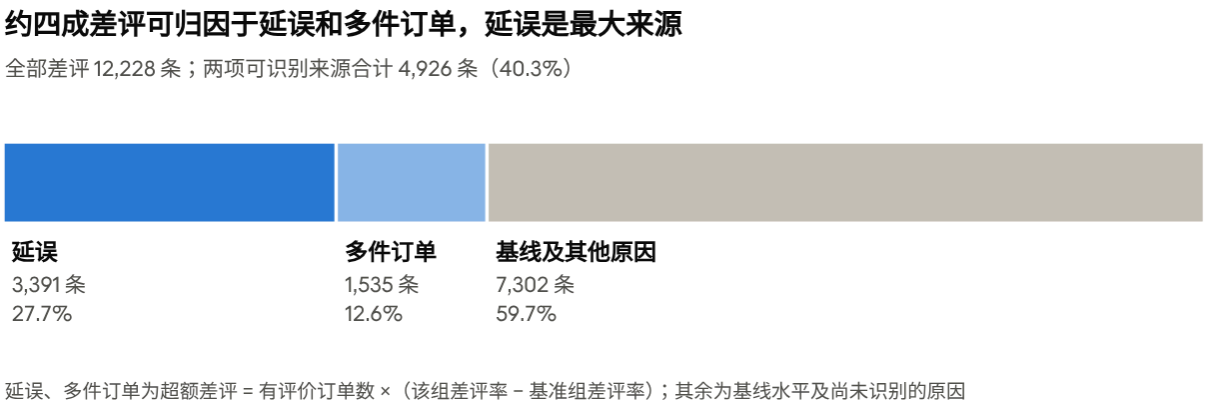
> 只能估计下 1~2 个月的短期影响，评分对销量的长期影响可能更大；把每月评价门槛提高到 10 条时样本减半，置信区间略微跨过 0。

那么，差评从哪里来？

3 差评从哪来：承诺没兑现与收货不完整

3.1 约四成差评可以归因于两个原因

分析期内共有 12,228 条差评。按超额差评计算，延误约造成 28%，多件订单约 13%，合计约四成。



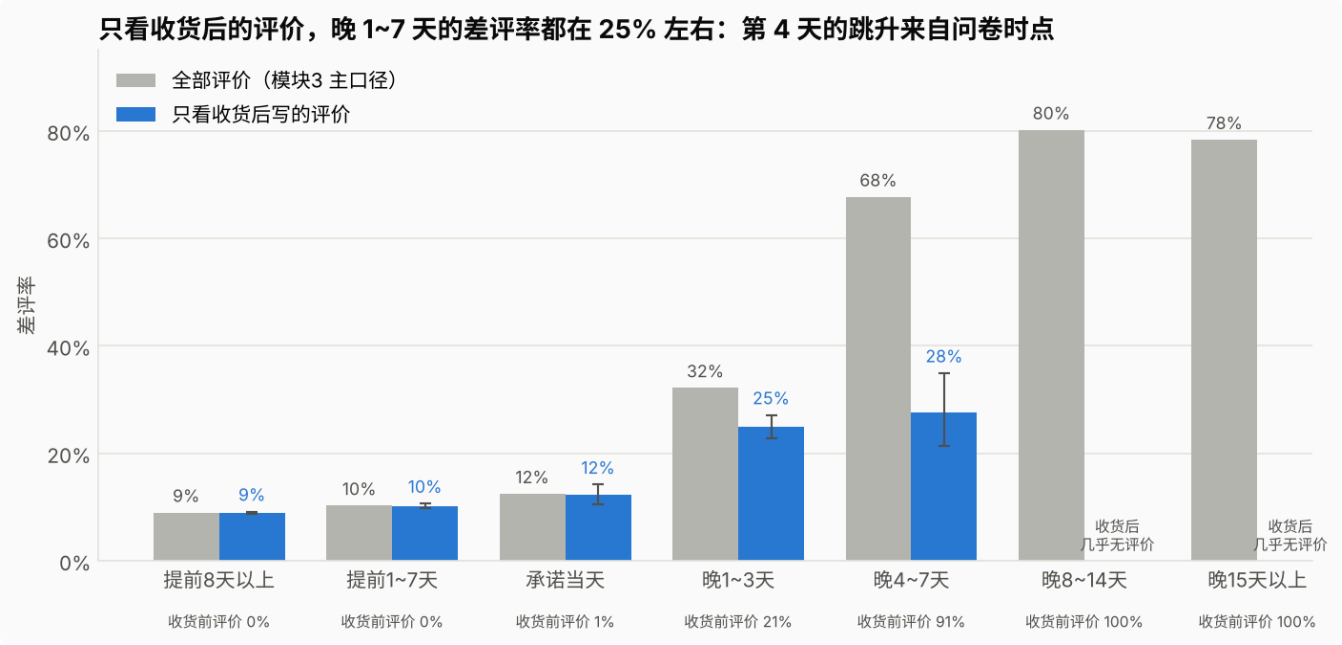
python/s2_impact_sizing.ipynb · 2017-01 至 2018-08 全部有评价订单

超额差评 = 有评价订单数 ×（该组差评率 − 基准组差评率）。延误的估计对口径敏感：只看收货后写的评价，延误造成的差评约为 8%（原因见 3.2 节）。其余约六成属于基线水平（准时送达的单件订单也有约 7.5% 的差评率）和尚未识别的原因。

> 超额差评是对比估算，不是因果证明：延误订单、多件订单与对照组之间可能还有其他差异（如品类、价格）。

3.2 买家在意的是承诺日到了货有没有到，而不是晚了几天

延误订单的差评率为 62.4%，准时订单为 9.2%（6.8 倍）。早期分析发现差评率在延误第 4 天"跳升"，回头检验发现，这个跳升来自评价的时点，而不是买家的容忍度。



Olist 在买家收货、或承诺送达日到达时发出满意度问卷。数据印证了这一点：准时订单的问卷在送达后 1 天发出，延误订单的问卷在承诺日后 2~4 天发出，那时多数订单还没送达。因此，晚 1~3 天的订单只有 21% 的评价写于收货前，晚 4~7 天达到 91%，差评率的跳升恰好发生在这里。只看收货后写的评价，晚 1~3 天和晚 4~7 天的差评率分别为 25% 和 28%，差别不显著。

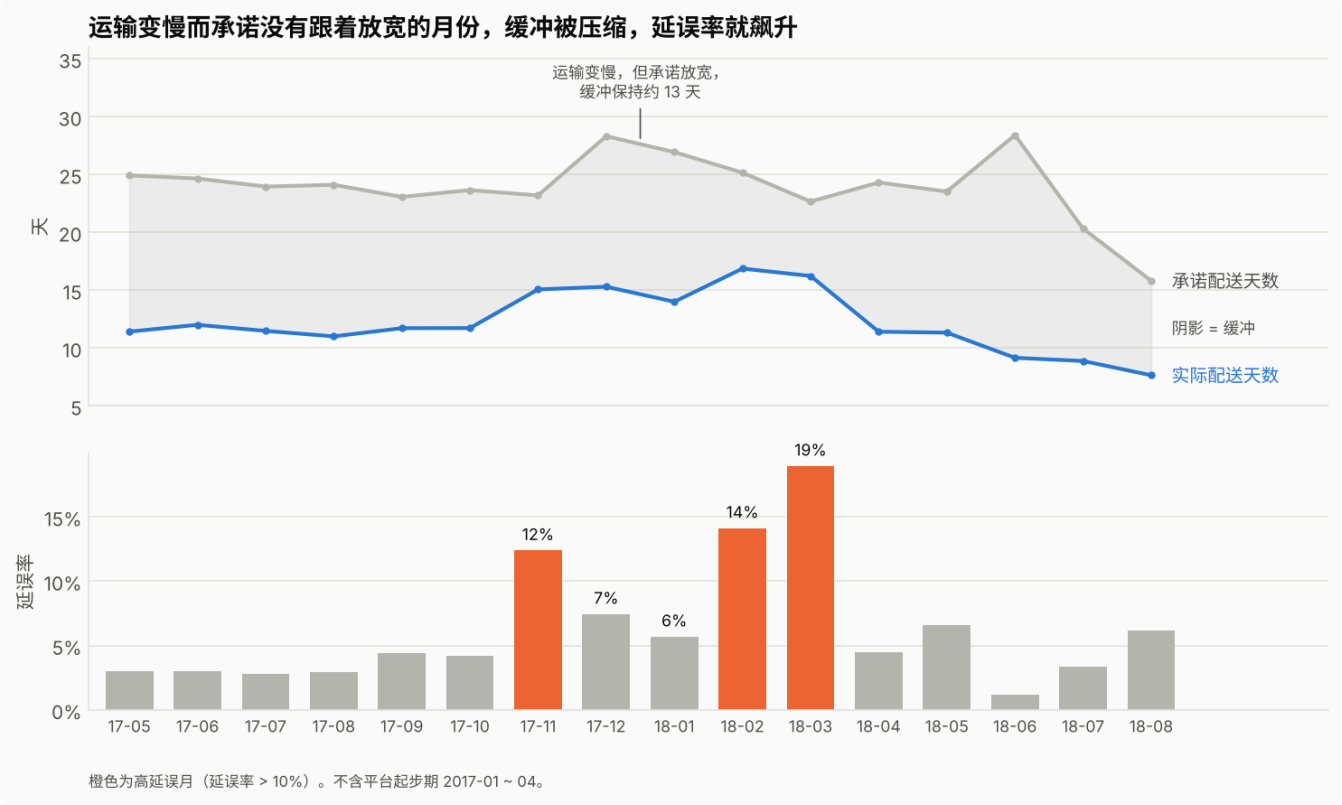
含义： 差评的关键时刻是承诺送达日。一旦错过承诺日，晚几天差别不大；所以改进的重点是**让承诺日期能够兑现**，而不是在延误几天后补救。

> 收货前写的评价是买家"到了承诺日还没收到货"的真实反应，主口径保留它们；但延误效应的大小应给出区间：全部评价口径为 6.8 倍，只看收货后评价为 2.7 倍。

承诺日期为什么会失准？

3.3 延误集中的 3 个月：运输变慢了，承诺却没有跟着放宽

2017-11、2018-02、2018-03 只占 22% 的订单，却贡献了 48% 的延误。这几个月的运输时长约 12.5 天（其他月份约 8.3 天），承诺天数却没有延长，缓冲从约 12.7 天压缩到约 7.6 天。



这 3 个月并不都是订单高峰：2018-02、2018-03 的订单量都低于 2018-01。2017-12 和 2018-01 是现成的对照：运输同样变慢，但承诺天数放宽到 27~28 天，延误率只有 7.5% 和 5.7%。按月看，延误率与缓冲天数的相关系数为 −0.79，比与订单量的相关（0.57）更紧密。

如果这 3 个月的承诺也跟着运输时长放宽 4~6 天、保持平常的缓冲，3,158 单延误中约 1,223 单（39%）会变为按时送达。

含义： 平台不能直接控制运输速度，但可以控制承诺日期。按运输时长动态校准承诺，比扩充运力成本更低。

> 运输为什么在这几个月变慢，现有数据无法回答，订单量大可能是原因之一；承诺天数变长可能降低下单转化，需要实验验证。延误也集中在部分州：RJ 在其他月份的延误率为 6.6%（SP 3.6%），高延误月达 31%，但常态差距带来的差评很少（第 5 章）。

3.4 卖家发货超时是平台可以直接约束的延误来源

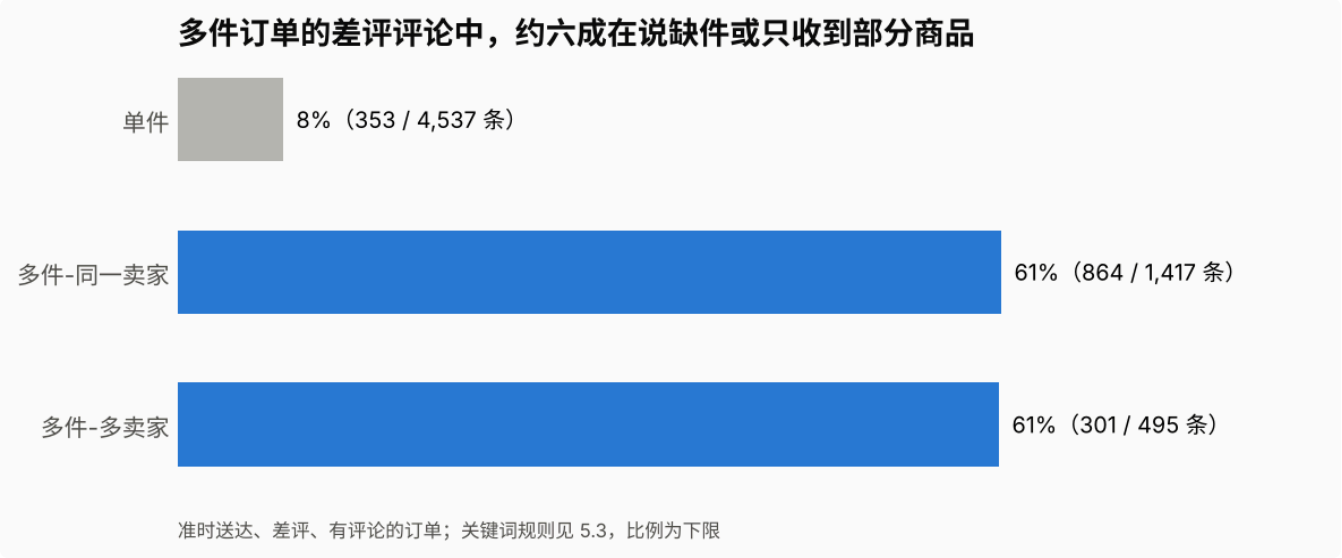
72% 的延误订单中，卖家是准时发货的，延误主要来自物流。但卖家超时发货会让延误风险从 5.4% 升到 21.2%（3.9 倍）。

订单一旦延误，无论卖家是否超时，差评率都在 62%~63%（p = 0.47）。即使最终准时送达，卖家超时的订单差评率仍更高（13.2% vs 8.3%）。在 1,074 个同时有两类订单的卖家内部对比，其中约 2.8 个百分点（95% 置信区间 1.8~3.7）来自等待时间本身，其余来自超时卖家整体质量较差。

含义： 发货超时只涉及约 9% 的订单，但规则简单，平台可以直接执行。

3.5 多件订单的差评主要来自收货不完整

准时送达的订单中，单件订单差评率 7.5%，多件且同一卖家 21.0%，多件且多个卖家 46.9%。评论文本显示，多件订单的差评中约六成在说缺件或只收到部分商品。



判断规则来自多件与单件订单差评评论的词频比较：多件订单特有的词集中在"两个""只""缺"上。人工抽查 30 条被规则匹配的多件订单评论，全部在说收货不完整，例如"买了 3 件只收到 1 件""买了 2 件只收到 1 件，系统却显示已送达"。数据中每笔订单只有一个送达时间，多件商品分包裹寄送时，可能第一个包裹到达，订单就被标记为已送达。

含义： 改进方向是完整交付：按包裹追踪，全部送达才标记"已送达"，缺件时主动补发或退款。

> 关键词规则会漏掉部分说法，六成是下限；无法区分卖家漏发和分包裹后丢件。

差评和延误在卖家之间是平均分布的吗？

4 供给侧：问题集中在少数卖家，新卖家大多没有起步

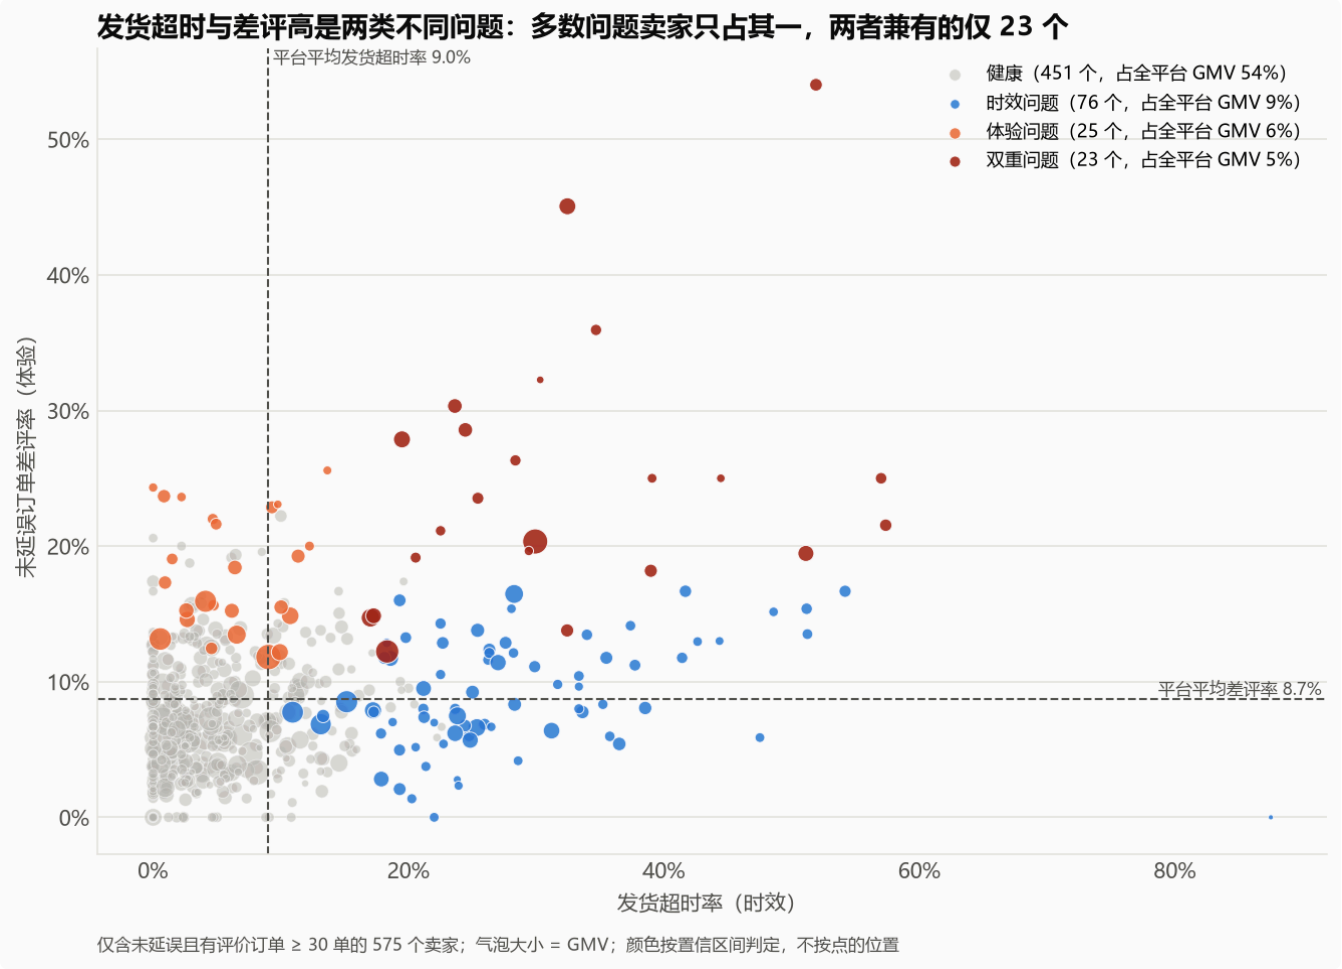
4.1 前 20% 的卖家贡献 82% 的 GMV

2,945 个有成交的卖家中，前 1%（29 个）贡献 26% 的 GMV，前 20% 贡献 82%，后 50% 只贡献约 3%。 一半卖家平均每月不到一单；2,370 个卖家（80%）的未延误有评价订单不足 30 单，无法单独判断好坏，合计贡献 25% 的 GMV。

含义： 头部卖家可以逐个管理；长尾卖家只能用平台规则（自动发货提醒、超时预警）统一管理。

4.2 32~40 个头部问题卖家是差评治理的重点

对 427 个样本充足的头部卖家，用两个卖家可控的指标（未延误订单差评率、发货超时率）分类：328 个健康，59 个时效问题，21 个体验问题，19 个双重问题。



图中画的是全部 575 个样本充足的卖家（包括 148 个腰部卖家），所以"两者兼有"为 23 个（头部 19 + 腰部 4）。判定标准是指标的 95% 置信区间下限高于平台平均，但这只控制了单个卖家的误判：575 个卖家逐一检验，即使都和平台一样，也预计约有 14 个被误判。改用精确检验和多重比较校正（BH）后，头部体验 / 双重问题卖家从 40 个减为 32 个，全部在原名单中，贡献了原超额差评的九成。

损害差异很大：每个双重问题卖家约多造成 26 条差评，体验问题约 21 条，时效问题约 2 条。双重问题卖家的商品明显更重更大（平均约 4.7 kg），可能与运输破损有关；只有体验问题的卖家商品并不更重，原因需要从商品质量和描述一致性上找。

含义： 不需要全面整顿，按损害整改这 32~40 个卖家即可；时效问题卖家数量多但单个损害小，适合用平台规则统一约束。

存量卖家的问题集中在少数头部。那么新卖家呢？

4.3 签约后 57% 的卖家 90 天内一单未卖

每 1,000 条营销线索最终带来 105 个签约、45 个激活、24 个健康卖家。

观察期满 90 天的 667 个签约卖家中，57% 在 90 天内一单未卖，21% 只卖了 1~2 单，只有 22% 达到健康（≥ 3 单）。线索到签约的流失比例最大（约 89%），但签约后的流失更值得关注：这时销售成本已经投入，卖家却没有起步。激活慢且匀速：签约 30 天时只有 16.5% 的卖家卖出首单。

渠道差异出在签约之后：付费搜索与自然搜索的签约率相同（12.3% vs 11.8%），签约后 90 天的激活率更高（55% vs 39%，p = 0.003）。6 个渠道两两比较共 15 组，按最保守的校正方法，这一差异刚好仍显著，应视为较强但不完全确定的证据。另有 14.5% 的线索来源记录为 unknown。

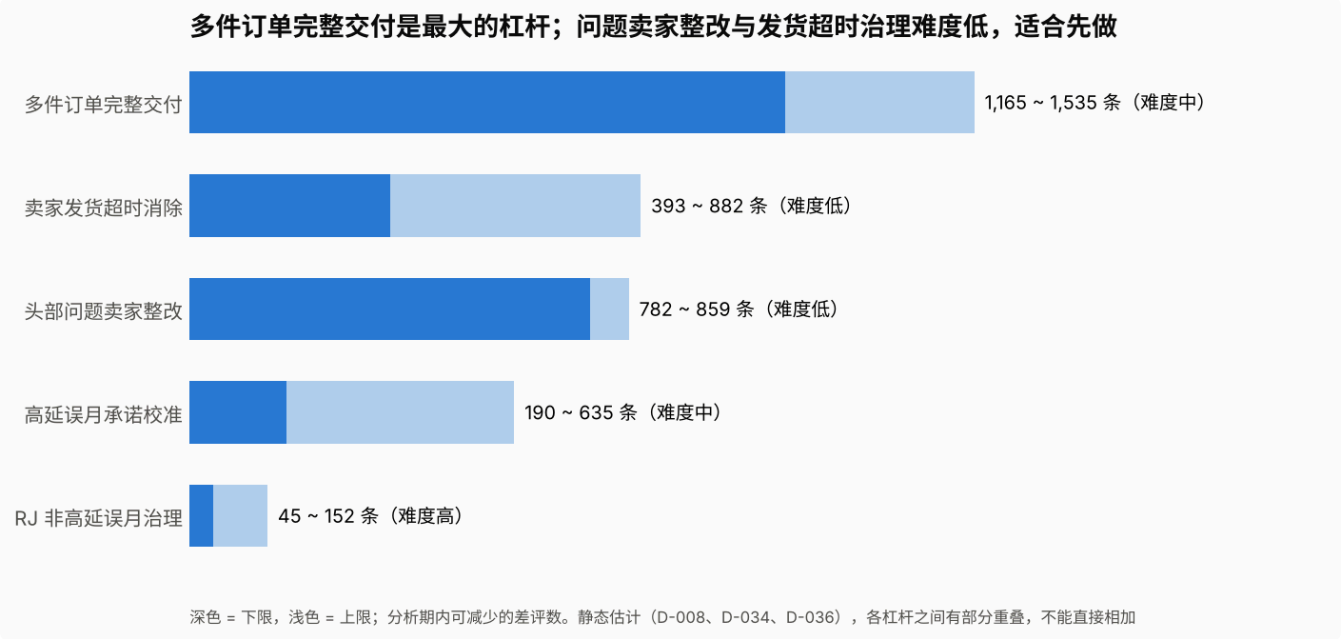
含义： 结合 2.2 节，新卖家在分存量需求，卖家获取应以质量为目标：把入驻扶持前置到签约后约第 14 天（此时只有 7% 的卖家已开始卖货），补全渠道追踪与获客成本数据后再决定预算。

> 只统计观察期满 90 天的签约，否则会严重低估激活率；观察窗口改为 60 / 120 天时，一单未卖的比例为 68% / 52%，结论不变。

前面几章找到了问题在哪里、为什么发生。下一章把各项改进换算成同一个单位，比较哪些最值得先做。

5 建议与优先级

把各项改进统一换算成"分析期内可减少的差评数"，并按 2.4 节换算成 GMV：多件订单完整交付是最大的杠杆；头部问题卖家整改和发货超时治理难度低，适合先做。



优先级	行动	依据	可减少差评	对应下月 GMV（上限）	验证方式
短期	发货截止前提醒，持续超时再处罚	超时使延误风险升至 3.9 倍，并直接带来差评（3.4）	393~882	约 6.0 万 BRL	先对部分卖家上线，比较超时率与差评率
短期	按损害整改头部问题卖家：双重问题限期整改并降低流量，体验问题先查差评原因	少数卖家集中了卖家可控的超额差评（4.2）	782~859	约 5.8 万 BRL	整改卖家与同类未整改卖家对比
中期	多件订单完整交付	约六成多件订单差评在说缺件（3.5）	1,165~1,535	约 10.4 万 BRL	选部分品类试点
中期	承诺日期按运输时长动态校准	运输变慢而承诺未调整（3.3）	190~635	约 4.3 万 BRL	A/B 测试，同时监控下单转化率
供给	卖家获取以质量为目标；入驻扶持前置到签约后第 14 天	新卖家分存量，57% 未起步（2.2、4.3）	不以差评计	—	扶持组与对照组的 90 天激活率
降低优先级	RJ 常态物流治理	常态差距小（3.3）	45~152	约 1.0 万 BRL	—

区间与难度的依据。 与延误相关的杠杆，上限按全部评价、下限按收货后评价计算；问题卖家按多重比较校正前后；多件订单的下限只算评论中明确提到收货不完整的差评。短期 = Olist 用现有规则和运营手段就能做；中期 = 需要改造 Olist 自己的系统；RJ 依赖外部承运商。

撤回的两条早期建议。 "对晚于承诺 3 天仍未送达的订单主动干预"的依据不成立（3.2 节）；"为高峰期准备运力预案"改为承诺日期校准（3.3 节）。

按 GMV 换算，单项改进约为分析期 GMV 的 0.1%~0.8%。体验改进保护的是口碑和卖家销量，增长本身仍取决于需求（第 2 章）。

6 局限与下一步

6.1 局限

- **观察数据，不是实验。** 超额差评、卖家内部对比、卖家 × 月份对比都只能控制部分干扰因素，结论表示关联与可能的机制，而不是严格的因果效应。
- **杠杆为静态估计。** 区间反映口径的不确定性，不含实施成本和需求变化；各杠杆互有重叠，不能相加。差评与 GMV 的换算只覆盖 1~2 个月的短期影响。
- **评价的口径影响效应大小。** 延误效应在 2.7~6.8 倍之间；没有评价的订单延误率（23.8%）是有评价订单（6.7%）的 3.5 倍，只用有评价订单计算可能低估延误的影响。
- **文本规则与复购率都是下限。** 关键词规则会漏掉部分说法；复购率受观察期不足影响。

- **数据缺口。** 没有承运商信息（无法解释运输为什么变慢）、渠道成本（无法评估获客投入产出）和佣金数据（GMV 不等于 Olist 收入）。

6.2 下一步

1. **剩余约六成差评的原因**：对评论文本做主题分析（商品质量、描述不符、运输破损等）。
2. **实验设计**：为承诺日期校准和发货提醒设计 A/B 测试，以差评率为主要指标、下单转化率为护栏。
3. **运输变慢的原因**：结合承运商和线路数据，按线路拆分运输时长。
4. **品类分析**：检验体验问题卖家的商品质量与描述一致性。
5. **同期群留存与在售卖家流失**：在处理右删失的前提下，追踪买家和卖家的长期表现。

附录

A 术语与口径

术语	口径
有效订单	状态为已送达、状态与时间戳无矛盾的订单，分析窗口内共 96,203 单
GMV（商品交易额）	有效订单的商品金额之和，不含运费，不等于 Olist 收入
差评	评分为 1~2 分；一单多条评价时取最后作答的一条
延误	实际送达日期晚于承诺送达日期
缓冲天数	承诺配送天数比实际配送天数多出的天数（按月平均）
高延误月	月度延误率超过 10% 的月份：2017-11、2018-02、2018-03（原称"高峰月"）
收货前评价	满意度问卷发出日期早于实际送达日期的评价
收货不完整	差评评论提到缺件或只收到部分商品（关键词规则）
卖家发货超时	单卖家订单中，交给物流的时间晚于发货截止时间
复购	在 2 个及以上不同日期下过有效订单
超额差评	有评价订单数 ×（该组差评率 − 基准组差评率）
头部卖家 / 样本不足	GMV 排名前 20% 的卖家 / 未延误且有评价的单卖家订单少于 30 单
激活 / 健康 / 流失	签约后 90 天内有效订单 ≥ 1 单 / ≥ 3 单 / 0 单

术语	口径
右删失	观察期未结束，结果还没来得及发生；不处理会低估复购率和激活率

B 稳健性检验汇总

检验	结果	结论是否改变
改用首次评分、排除时间戳异常、多卖家订单按主卖家归属	差评率变动均不超过 0.5 个百分点	否
排除收货前写的评价	延误的差评倍数从 6.8 降至 2.7；"第 4 天临界点"消失	方向不变，幅度变小；临界点的解释已修正
差评与 GMV：评价门槛 5 / 10 条，结果窗口 1 / 2 个月	差评率 +10 个百分点，下月 GMV −4%~−10%	方向不变
高延误月：排除平台起步期后按月比较	延误率与缓冲天数相关系数 −0.79	解释不依赖延误率的定义
多件订单关键词规则：人工抽查	抽查的 30 条多件订单评论全部属实	否
卖家分层阈值（7 种情景）	头部问题卖家 GMV 占比 17%~22%，损害排序不变	否
卖家分层：只用单件订单 / 多重比较校正	40 个中 34 个仍有体验问题 / 校正后为 32 个	否
卖家内部对比的评价门槛（1 / 3 / 5 条）	超时带来的差评率增幅 2.8~2.9 个百分点	否
漏斗观察窗口（60 / 90 / 120 天）	90 天内未开单比例 68% / 57% / 52%	否

C 关键口径决策

完整的决策记录（D-001 至 D-039）见仓库 `docs/decision_log.md`。与本报告结论直接相关的有：

编号	决策	对应章节
D-004	GMV 只算商品金额，不含运费	第 2 章
D-016	分析窗口 2017-01 至 2018-08	全文

编号	决策	对应章节
D-021	收货前的评价保留并做敏感性分析	3.2
D-022	复购按不同日期计算	2.1
D-024	无评价订单保留在宽表中	6.1
D-030	卖家分层规则	4.2
D-031	漏斗激活与健康的 90 天观察窗口	4.3
D-033	首单体验只用 2018-03 前首购的买家	2.3
D-034	建议统一换算为可减少的差评数	第 5 章
D-035	"高峰月"改称"高延误月"，按缓冲天数解释	3.3
D-036	延误相关杠杆给出区间	3.2、第 5 章
D-037	差评换算为下月 GMV	2.4、第 5 章
D-038	多件订单收货不完整的判定规则	3.5
D-039	卖家判定补充多重比较校正	4.2、4.3

D 复现

代码与文档见 github.com/LeeMichael-L/olist-analytics。环境为 MySQL 8.0 及以上、Python 3.13。

1. 从 Kaggle 下载 Olist 主数据集和营销漏斗数据集，放入 `data/raw/`。
2. 按 `sql/01_ods` → `02_dwd` → `03_dws` → `04_ads` 的顺序执行建表脚本，每个脚本末尾都有核对查询。
3. 在 `python/` 中按 `s1_overview` → `m1` → `m5` → `m3` → `m6` → `m7` → `s2_report_checks` → `s2_impact_sizing` 的顺序运行 notebook，本报告的全部图表和数字均由此生成。